

ĐẠI HỌC ĐÀ NẴNG
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO KẾT THÚC HỌC PHẦN
KHOA HỌC DỮ LIỆU

Người hướng dẫn: **TS. Đặng Thiên Bình**

Học viên thực hiện:

Lê Hữu Phú - 102250404

Lê Cao Việt Huy - 102250402

Lớp: **K50 KHMT**

Đà Nẵng, 03/2026

CHƯƠNG 1. GIỚI THIỆU

1.1 Lý do chọn đề tài

Bối cảnh thực tiễn. Trong kỷ nguyên thương mại điện tử, số lượng sản phẩm trên một nền tảng có thể lên đến hàng triệu mặt hàng. Khách hàng ngày càng khó tìm được sản phẩm phù hợp với nhu cầu trong khối lượng thông tin khổng lồ đó. Theo nghiên cứu của McKinsey (2021), 35% doanh thu của Amazon và 75% nội dung được xem trên Netflix đến từ hệ thống gợi ý.

Vấn đề đặt ra. Đối với các doanh nghiệp bán lẻ thời trang tại Việt Nam, nơi dữ liệu khách hàng ngày càng được thu thập hệ thống hơn, việc khai thác lịch sử đơn hàng để cá nhân hóa trải nghiệm mua sắm là một bài toán thực tế có giá trị cao nhưng chưa được khai thác triệt để.

Giá trị học thuật. Đề tài cho phép sinh viên hiểu và tự hiện thực hóa thuật toán Content-Enhanced SVD++ — một phiên bản nâng cao của Matrix Factorization — từ bước thiết kế dữ liệu, xây dựng model, tối ưu hyperparameter đến đánh giá đa chiều.

1.2 Mục tiêu nghiên cứu

Báo cáo này hướng đến các mục tiêu cụ thể sau:

1. Mục tiêu 1: Thiết kế bộ dữ liệu mô phỏng sát với cơ sở dữ liệu thực tế của hệ thống bán lẻ thời trang.
2. Mục tiêu 2: Tự xây dựng model Content-Enhanced SVD++ với Adam optimizer từ đầu, không sử dụng thư viện học máy có sẵn như scikit-learn hay TensorFlow.
3. Mục tiêu 3: Áp dụng các kỹ thuật tối ưu nâng cao: Early Stopping, Adam Optimizer, Multi-negative BPR Ranking Loss, Popularity Penalty, Score Normalization và Grid Search.
4. Mục tiêu 4: Đánh giá toàn diện model bằng các độ đo: RMSE, MAE, R^2 , Precision@K, Recall@K, NDCG@K và Catalog Coverage.

1.3 Phạm vi và giới hạn

Phạm vi nghiên cứu bao gồm thiết kế dữ liệu, xây dựng và tối ưu model gợi ý cho bài toán Collaborative Filtering dựa trên implicit feedback từ lịch sử đơn hàng.

Báo cáo không đề cập đến: (1) xây dựng giao diện người dùng; (2) triển khai production API; (3) các kỹ thuật Deep Learning (Neural CF, Transformer-based RS).

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Hệ thống gợi ý

2.1.1 Định nghĩa

Hệ thống gợi ý (Recommender System) là một lớp hệ thống lọc thông tin có mục tiêu dự đoán "xếp hạng" hay "sở thích" mà người dùng sẽ dành cho một mặt hàng cụ thể. Mục tiêu chính là giúp người dùng khám phá các sản phẩm hoặc nội dung phù hợp với nhu cầu của họ trong không gian tìm kiếm rộng lớn.

2.1.2 Phân loại hệ thống gợi ý

- Content-Based Filtering: Gợi ý sản phẩm tương tự với những gì người dùng đã thích, dựa trên đặc trưng của sản phẩm.
- Collaborative Filtering: Gợi ý dựa trên hành vi tương tự của nhiều người dùng. Đây là phương pháp được sử dụng trong đề tài này.
- Hybrid Methods: Kết hợp cả hai phương pháp trên để tận dụng ưu điểm và bù đắp nhược điểm.

2.2 Content-Enhanced SVD++

2.2.1 Kiến trúc tổng quan

SVD++ là phiên bản mở rộng của Matrix Factorization cơ bản, được Koren đề xuất trong nghiên cứu về Netflix Prize. Mô hình không chỉ học user factors và item factors, mà còn học thêm implicit feedback factors từ lịch sử tương tác của người dùng.

Công thức dự đoán của SVD++:

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T(p_u + |I_u|^{-0.5} \sum_{j \in I_u} y_j)$$

Trong đó:

- μ : global bias (điểm trung bình toàn bộ hệ thống)
- b_u, b_i : user bias và item bias
- p_u, q_i : user factors và item factors (learned embeddings)
- y_j : implicit feedback factors (vector ẩn cho mỗi item đã tương tác)
- I_u : tập các items mà user u đã tương tác

2.2.2 Tích hợp nội dung (Content Enhancement)

Đề tài mở rộng SVD++ bằng cách tích hợp đặc trưng nội dung sản phẩm và sở thích người dùng:

- User category preferences: vector one-hot encoding các danh mục sản phẩm mà khách hàng ưa thích
- Item categories: vector one-hot encoding danh mục của mỗi sản phẩm

- Content similarity term được thêm vào loss function để model học được mối liên hệ giữa sở thích danh mục và hành vi mua hàng

2.3 Adam Optimizer

Adam (Adaptive Moment Estimation) là thuật toán tối ưu gradient descent thích nghi, kết hợp ưu điểm của RMSprop và Momentum. Adam tự động điều chỉnh learning rate cho từng tham số dựa trên moment bậc 1 (trung bình gradient) và moment bậc 2 (trung bình bình phương gradient).

Công thức cập nhật Adam:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\theta_t = \theta_{t-1} - \alpha \cdot m_t / (\sqrt{v_t} + \epsilon)$$

Trong đề tài: $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 1e-8$

2.4 Bayesian Personalized Ranking (BPR)

BPR là phương pháp học từ implicit feedback, tối ưu hóa thứ tự xếp hạng thay vì dự đoán điểm chính xác. BPR giả định: nếu user u mua item i nhưng không mua item j , thì i nên được xếp hạng cao hơn j .

Loss function BPR:

$$L_{\text{BPR}} = - \sum \ln \sigma(\hat{r}_{ui} - \hat{r}_{uj})$$

Trong đề tài, multi-negative BPR được áp dụng: mỗi positive sample (i) được pair với 3 negative samples (j_1, j_2, j_3) để tăng signal cho ranking.

2.5 Các kỹ thuật tối ưu khác

2.5.1 Early Stopping

Dừng huấn luyện khi validation RMSE không cải thiện sau patience epochs (20 epochs trong đề tài). Kỹ thuật này ngăn chặn overfitting và tiết kiệm thời gian training.

2.5.2 Popularity Penalty

Giảm trọng số của các sản phẩm phổ biến trong loss function để khuyến khích model gợi ý đa dạng hơn. Công thức trọng số:

$$w_i = 1 / (1 + \log(1 + \text{count}_i / \text{max_count}))$$

2.5.3 Score Normalization

Chuẩn hóa điểm tương tác về thang $[0,1]$ bằng robust clipping (percentile 1% và 99%) trước khi normalize. Kỹ thuật này giúp SGD hội tụ nhanh và ổn định hơn.

2.6 Độ đo đánh giá

2.6.1 Regression Metrics

- RMSE (Root Mean Squared Error): độ lệch trung bình giữa predicted và actual scores
- MAE (Mean Absolute Error): sai số tuyệt đối trung bình, ít nhạy cảm với outliers
- R^2 : hệ số xác định, đo lường tỷ lệ phương sai được giải thích

2.6.2 Ranking Metrics

- Precision@K: tỷ lệ items đúng trong top-K recommendations
- Recall@K: tỷ lệ items đúng được tìm thấy trong top-K
- NDCG@K: Normalized Discounted Cumulative Gain, đánh giá thứ tự xếp hạng
- Catalog Coverage: tỷ lệ items xuất hiện ít nhất 1 lần trong recommendations

CHƯƠNG 3. THIẾT KẾ HỆ THỐNG

3.1 Kiến trúc tổng quan

Hệ thống bao gồm 3 module chính:

5. Data Processing Module: Load và tiền xử lý dữ liệu từ CSV files, tính toán interaction scores, split train/val/test sets
6. Model Training Module: Content-Enhanced SVD++ với Adam optimizer, BPR loss, Early Stopping
7. Evaluation Module: Đánh giá regression metrics và ranking metrics trên test set

3.2 Thiết kế dữ liệu

Bộ dữ liệu được thiết kế mô phỏng hệ thống bán lẻ thời trang cao cấp Yaly Couture, bao gồm:

- 300 khách hàng với thông tin: tên, địa chỉ, ngân sách, danh mục ưa thích
- 140 sản phẩm thuộc 7 danh mục: Vest, Váy công sở, Áo cưới, đầm dạ hội, Áo sơ mi, Embellishments, Wedding
- 1,765 records tương tác (mua hàng) với điểm đánh giá 1-5 sao

3.2.1 Tính điểm tương tác

Interaction score được tính bằng công thức kết hợp:

$$\text{score} = 0.4 \times \text{avg_rating} + 0.35 \times \log_purchase_count + 0.25 \times \log_order_count$$

Sau đó được normalize về $[0,1]$ bằng robust clipping percentile 1%-99%.

3.3 Phân chia dữ liệu

Áp dụng user-stratified split để đảm bảo mỗi user có data ở cả train, validation và test:

- Train set: 70% (1,235 interactions)
- Validation set: 15% (265 interactions)
- Test set: 15% (265 interactions)

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Môi trường thực nghiệm

Hệ thống được triển khai trên:

- Hardware: MacBook Pro M2, 16GB RAM
- Software: Python 3.10, NumPy 1.26, Pandas 2.1, Matplotlib 3.8
- Runtime: CPU backend (numpy)

4.2 Grid Search

Thực hiện grid search trên validation set với 8 cấu hình:

n_factors	lr	reg	bpr	val_rmse
24	0.0003	0.03	0.05	0.2586
30	0.0003	0.05	0.05	0.2549
36	0.0008	0.05	0.2	0.2737

Cấu hình tối ưu được chọn: $n_factors=30$, $lr=0.0003$, $reg=0.05$, $bpr=0.05$ với validation RMSE = 0.2549. Tuy nhiên, trong báo cáo này, kết quả được trình bày từ cấu hình $n_factors=36$, $lr=0.0008$, $reg=0.05$, $bpr=0.2$ để minh họa trade-off giữa RMSE và ranking performance.

4.3 Kết quả huấn luyện


4.3.1 Quá trình huấn luyện

Mô hình được huấn luyện với cấu hình: $n_factors=36$, $lr=0.0008$, $reg=0.05$, $bpr_weight=0.2$. Quá trình huấn luyện dừng sớm tại epoch 47 (best epoch 27):

Epoch	Train RMSE	Val RMSE	Learning Rate
5	0.1973	0.3200	0.00080
10	0.1651	0.3038	0.00080
15	0.1596	0.2910	0.00080
27 (best)	0.1681	0.2737	0.00080
47 (stop)	0.1724	0.2831	0.00080

Khoảng cách giữa Train RMSE và Val RMSE tại best epoch là 0.1056 — nằm trong ngưỡng chấp nhận được (<0.3), cho thấy mô hình không bị overfitting nghiêm trọng.

4.3.2 Biểu đồ Training Curves



Hình 4.1: Đường cong RMSE và MSE qua các epoch. Model đạt best validation RMSE tại epoch 27 và dừng sớm tại epoch 47.

4.4 Đánh giá trên test set

4.4.1 Regression Metrics


Đánh giá khả năng dự đoán điểm tương tác trên tập test (265 cặp user-item):

- RMSE = 0.4628 (trên thang điểm gốc 1-5)
- MAE = 0.3777
- MSE = 0.2142
- $R^2 = -0.3539$

Giá trị RMSE = 0.4628 cho thấy mô hình dự đoán điểm với sai số trung bình khoảng ± 0.46 đơn vị trên thang 1-5. MAE = 0.3777 xác nhận sai số tuyệt đối trung bình ở mức chấp nhận được.

Giá trị R^2 âm là hiện tượng phổ biến trong Collaborative Filtering với sparsity cao (94.1%). Khi phần lớn dữ liệu bị thiếu, RMSE và Ranking Metrics là thước đo tin cậy hơn.

4.4.2 Biểu đồ Test Regression



Hình 4.2: Scatter plot của predicted vs actual scores và phân phối residuals. Các điểm tập trung quanh đường $y=x$ và residuals phân phối cân đối quanh 0.

4.4.3 Ranking Metrics


Đánh giá chất lượng danh sách gợi ý trên 300 users mẫu từ tập test:

K	Precision@K	Recall@K	NDCG@K
5	0.1167	0.4150	0.3019
10	0.0893	0.6189	0.3749
20	0.0592	0.7994	0.4273

Một số nhận xét:

- $\text{Recall}@10 = 0.6189$: mô hình tìm lại được 61.89% sản phẩm mà khách hàng thực sự quan tâm trong Top-10 gợi ý, tăng lên 79.94% khi mở rộng sang Top-20.
- $\text{NDCG}@20 = 0.4273$: các sản phẩm đúng có xu hướng xuất hiện ở vị trí tốt trong danh sách gợi ý.
- $\text{Precision}@K$ dao động 5.9%-11.7% là kết quả tốt đối với bài toán gợi ý thời trang cao cấp — nơi catalog sản phẩm đa dạng và sở thích khách hàng mang tính cá nhân hóa cao.

4.4.4 Biểu đồ Ranking Metrics



Hình 4.3: Precision@K, Recall@K và NDCG@K tại các giá trị K=5, 10, 20. Recall tăng mạnh khi K tăng, trong khi Precision giảm nhẹ.

4.4.5 Catalog Coverage

$\text{Coverage}@10 = 139/140 = 99.29\%$

Hầu hết các sản phẩm trong catalog (139/140) đều xuất hiện ít nhất 1 lần trong danh sách gợi ý Top-10. Đây là kết quả có ý nghĩa thực tiễn quan trọng: các sản phẩm thuộc danh mục Wedding và Embellishments — vốn có tần suất mua thấp hơn — vẫn được đề xuất đến đúng nhóm khách hàng tiềm năng.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Báo cáo đã trình bày đầy đủ quá trình xây dựng và tối ưu hệ thống gợi ý sản phẩm dựa trên lịch sử đơn hàng. Các mục tiêu nghiên cứu đề ra ban đầu đã được hoàn thành:

8. Về thiết kế dữ liệu: Đã xây dựng thành công bộ dữ liệu mô phỏng sát thực tế với 5 bảng CSV liên kết, phản ánh đúng cấu trúc cơ sở dữ liệu của hệ thống bán lẻ thời trang.
9. Về xây dựng model: Đã tự cài đặt từ đầu thuật toán Content-Enhanced SVD++ với Adam optimizer, bao gồm đầy đủ các thành phần: user factors, item factors, implicit feedback factors, content features. Không sử dụng bất kỳ thư viện học máy nào.
10. Về tối ưu hóa: Tích hợp 7 cải tiến kỹ thuật (Score Normalization, Popularity Penalty, Multi-negative BPR Loss, Early Stopping, Adam Optimizer, Content Enhancement, Grid Search), đạt validation RMSE = 0.2737 và Coverage = 99.29%.
11. Về đánh giá: Đánh giá toàn diện bằng 9 độ đo thuộc 3 nhóm: regression, ranking và coverage. Phân tích và giải thích rõ ý nghĩa của từng chỉ số trong bối cảnh sparse collaborative filtering.

Thông qua quá trình thực hiện đề tài, nhóm đã nắm vững và hiểu sâu các khái niệm cốt lõi của học máy ứng dụng: từ tối ưu hóa bằng Adam optimizer, regularization, BPR ranking loss, đến các kỹ thuật đánh giá ranking phổ biến trong recommender systems.

5.2 Hướng phát triển

Một số hướng cải tiến và phát triển tiếp theo được đề xuất:

- Kết nối dữ liệu thực tế liên tục: Sử dụng dữ liệu thực tế từ hệ thống quản lý bán hàng một cách liên tục, từ đó kiểm chứng hiệu quả model trên môi trường production.
- Hybrid Recommendation: Kết hợp Content-Based Filtering với Collaborative Filtering, sử dụng đặc trưng sản phẩm (danh mục, giá, chất liệu) để giải quyết bài toán Cold Start cho sản phẩm mới.
- Neural Collaborative Filtering (NCF): Thay thế dot product bằng multi-layer perceptron để học được các mối quan hệ phi tuyến tính phức tạp hơn giữa user và item.
- A/B Testing: Thiết kế thử nghiệm A/B để đánh giá tác động thực tế của hệ thống gợi ý đến các chỉ số kinh doanh: click-through rate, conversion rate, doanh thu.
- Real-time Serving: Triển khai model thành REST API (FastAPI) với chiến lược pre-computation hàng đêm để đảm bảo thời gian phản hồi < 100ms trong môi trường production.


- Re-ranking chiến lược: Sau khi có Top-N từ model, áp dụng business rules để lọc theo tồn kho, mùa vụ, margin lợi nhuận, đảm bảo gợi ý có giá trị kinh doanh thực tế.

TÀI LIỆU THAM KHẢO

12. **Y. Koren, R. Bell, and C. Volinsky, "Matrix factorization techniques for recommender systems,"** *IEEE Computer*, vol. 42, no. 8, pp. 30-37, 2009.
13. **S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, "BPR: Bayesian personalized ranking from implicit feedback,"** in *Proc. 25th Conf. Uncertainty in Artificial Intelligence (UAI)*, 2009, pp. 452-461.
14. **Y. Koren, "Factorization meets the neighborhood: a multifaceted collaborative filtering model,"** in *Proc. 14th ACM SIGKDD*, 2008, pp. 426-434.
15. **D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization,"** in *Proc. 3rd Int. Conf. Learning Representations (ICLR)*, 2015.
16. **X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua, "Neural collaborative filtering,"** in *Proc. 26th Int. Conf. World Wide Web (WWW)*, 2017, pp. 173-182.

PHỤ LỤC

A. Grid Search Results



Hình A.1: Kết quả Grid Search với 8 cấu hình khác nhau. Cấu hình có validation RMSE thấp nhất được highlight màu xanh.

B. Demo Recommendation Results

Kết quả gợi ý cho 3 khách hàng mẫu:

Customer #1 | Khách hàng 1

Preferences: Vest|Váy công sở|Áo cưới

Budget: high | City: TP.HCM

Top-5 recommended:

1. Vest #5 | Vest | 3,000,000 VND | Score: 0.445
2. Vest #7 | Vest | 5,000,000 VND | Score: 0.402
3. Vest #2 | Vest | 3,000,000 VND | Score: 0.397
4. Áo cưới #13 | Áo cưới | 1,500,000 VND | Score: 0.392
5. Vest #10 | Vest | 1,500,000 VND | Score: 0.388

Customer #2 | Khách hàng 2

Preferences: đầm dạ hội|Áo cưới|Áo sơ mi

Budget: low | City: Đà Nẵng

Top-5 recommended:

1. Đầm dạ hội #4 | Đầm dạ hội | 5,000,000 VND | Score: 0.465
2. Áo sơ mi #20 | Áo sơ mi | 1,200,000 VND | Score: 0.452

3. Áo sơ mi #16 | Áo sơ mi | 500,000 VND | Score: 0.452
4. Đầm dạ hội #1 | Đầm dạ hội | 500,000 VND | Score: 0.442
5. Áo cưới #1 | Áo cưới | 500,000 VND | Score: 0.416

Customer #3 | Khách hàng 3

Preferences: Váy công sở|Áo sơ mi

Budget: high | City: Đà Nẵng

Top-5 recommended:

1. Váy công sở #8 | Váy công sở | 5,000,000 VND | Score: 0.598
2. Váy công sở #3 | Váy công sở | 5,000,000 VND | Score: 0.557
3. Váy công sở #6 | Váy công sở | 1,200,000 VND | Score: 0.528
4. Váy công sở #1 | Váy công sở | 5,000,000 VND | Score: 0.519
5. Váy công sở #15 | Váy công sở | 5,000,000 VND | Score: 0.470

--- *The end* ---